

FUNDAÇÃO GETULIO VARGAS
ESCOLA DE ECONOMIA DE SÃO PAULO (EESP)

Forecasting da exposição de gestoras a ações em redes de fundos

Evidência do mercado brasileiro de fundos, 2016–2021

João Paulo Zangrandi

Orientador: Prof. Maurício Ferraresi Junior

São Paulo
18 de junho de 2026

Resumo

Este trabalho mede a exposição das gestoras brasileiras a ações e formula um sistema de previsão inspirado em *demand-based asset pricing*. A unidade empírica é gestora $\times$ mês $\times$ ação: para cada ação, observa-se quais gestoras aumentaram ou reduziram exposição e testa-se se esse movimento pode ser previsto a partir do próprio histórico, do restante do mercado e da rede de fundos interconectados. O núcleo empírico usa as bases CONS e SH da CVM para medir exposição em R\$ e US\$ e a CDA Bloco 2 para reconstruir relações fundo $\rightarrow$ fundo, necessárias para representar estruturas FIC/master como grafo.

O resultado central de dados é que a exposição institucional é concentrada em *blue chips* e que as estruturas fundo-sobre-fundo são economicamente relevantes. A rede CDA não apresenta ciclos nos 72 meses analisados, respondendo à preocupação com estruturas circulares, mas revela profundidade de aninhamento e duplicação material: em ITUB4, a soma bruta intra-gestora é cerca de 37,6% maior do que a exposição de-duplicada. No forecasting, os modelos lineares e fatoriais mostram que a variação mensal é difícil de prever; já o nível da exposição em valor apresenta alguma reversão à média. A quantidade estimada de ITUB4, construída com preço B3/COTAHIST, entra como robustez para separar preço de quantidade. Ela confirma que a demanda aproximada em ações é mais ruidosa do que a exposição patrimonial em valor.

Palavras-chave: demand-based asset pricing; fundos de investimento; exposição em ações; forecasting; redes; CVM.

Sumário

Resumo	i
1 Introdução	1
2 Revisão Bibliográfica	3
2.1 Demand-based asset pricing	3
2.2 Fragilidade por propriedade comum	3
2.3 Métodos de previsão e fatores	3
2.4 Plataformas de investimento	4
3 Metodologia e Dados	5
3.1 Bases do núcleo empírico	5
3.2 Tratamentos de dados	6
3.3 Definição de exposição	6
3.4 Rede de fundos e problema preditivo	7
3.5 Quantidade estimada de ações	7
3.6 Unidade de análise	8
3.7 Avaliação preditiva	8
4 Resultados	9
4.1 Exposição e quantidade em ITUB4	9
4.2 Extensão para todas as ações	10
4.3 Rede fundo-sobre-fundo e duplicação	11
4.4 Previsão da variação mensal	12
4.5 Previsão do nível e reversão à média	13
4.6 Generalização do forecasting	15
4.7 Rede como preditor complementar	16
5 Conclusão	17

A	Apêndice: CDA e Estruturas Fundo-Sobre-Fundo	18
A.1	Por que a CDA aparece no projeto	18
A.2	O que é a CDA Bloco 2	18
A.3	Construção da base	18
A.4	Validação da CDA	19
A.5	De-duplicação intra-gestora	19
A.6	Resultados da rede CDA	20
A.7	Limitações da CDA	20

Capítulo 1

Introdução

O objetivo deste trabalho é medir e prever a exposição das gestoras brasileiras a ações usando informação de carteiras e de redes de fundos. A pergunta empírica nasce de uma ideia simples: se investidores institucionais têm demandas persistentes por ativos, então as carteiras observadas podem conter informação sobre comportamento futuro. A literatura de *demand-based asset pricing* fornece a motivação: preços não são determinados apenas por fundamentos agregados, mas também pela demanda de investidores com restrições, preferências e mandatos específicos (Koijen and Yogo, 2019; Gabaix and Koijen, 2021).

O caso brasileiro é adequado para esse exercício porque a CVM disponibiliza bases públicas de fundos. A CONS permite observar a composição consolidada das carteiras e a SH permite associar cada fundo à sua gestora e ao seu patrimônio líquido. Essas bases permitem medir exposição em valor, em R\$ e US\$, que é a medida mais direta de escala econômica e risco patrimonial. A dificuldade é que a CONS, por ser consolidada, apaga o caminho de fundos investindo em fundos. Para construir um sistema preditivo por grafo, o trabalho usa a CDA Bloco 2, que registra cotas de fundos e permite recuperar as arestas fundo→fundo.

O desenho preditivo é: para cada ação e mês, medir quem aumentou ou reduziu exposição; para cada gestora, usar seu próprio histórico, o comportamento das demais gestoras (o “restante do mercado”, ou $n - 1$) e a rede de fundos interconectados como informação para prever exposição futura. A quantidade estimada de ações, construída para ITUB4 com fechamento B3/COTAHIST (B3 S.A. — Brasil, Bolsa, Balcão, 2024), é mantida como robustez conceitual: ela ajuda a separar efeito de preço de mudança aproximada de quantidade, mas a medida principal de exposição do trabalho permanece em valor.

O trabalho responde a cinco perguntas:

1. Como medir a exposição das gestoras a ações em R\$ e US\$, com tratamento consistente de empréstimos de ações e grupos econômicos?
2. Como reconstruir a rede fundo→fundo que a CONS apaga ao consolidar carteiras?
3. Existem circularidades ou aninhamentos profundos nas estruturas FIC/master?
4. A exposição futura de uma gestora pode ser prevista a partir do próprio histórico, do restante do mercado e da rede?

5. A evidência inicial de ITUB4 se generaliza para outras ações?

Assim, a CDA não entra como base alternativa à CONS. As duas têm funções diferentes. A CONS mede a exposição final em ações; a CDA recupera o caminho de fundos sobre fundos que pode ser usado para modelar propagação, duplicação e risco de estruturas interconectadas. Os detalhes de tratamento da CDA permanecem no Apêndice A, mas a motivação da rede faz parte do núcleo do trabalho.

Capítulo 2

Revisão Bibliográfica

2.1 Demand-based asset pricing

Koijen and Yogo (2019) propõem um sistema de demanda por ativos no qual investidores institucionais escolhem carteiras em função de características dos ativos, preços e restrições próprias. A contribuição central para este TCC é tratar carteiras observadas como revelação de demanda. Em vez de olhar apenas para retornos ou fundamentos agregados, o pesquisador usa a composição das carteiras para inferir como diferentes investidores demandam ativos.

Gabaix and Koijen (2021) desenvolvem a hipótese de mercados inelásticos: fluxos podem ter impacto desproporcional sobre preços quando a demanda agregada por ações não é altamente elástica. Para este trabalho, a implicação é direta: se gestoras concentram demanda nas mesmas ações e ajustam posições de forma correlacionada, variações de exposição podem ser relevantes para preços e risco.

2.2 Fragilidade por propriedade comum

Greenwood and Thesmar (2011) mostram que a estrutura de propriedade pode gerar fragilidade de preços. Ativos detidos por investidores sujeitos a choques semelhantes tendem a ficar mais vulneráveis, pois vendas ou compras correlacionadas podem amplificar movimentos. No nosso contexto, as ações *crowded*, detidas por muitas gestoras, são candidatas naturais a esse tipo de fragilidade.

2.3 Métodos de previsão e fatores

O uso de PCA e análise fatorial segue a lógica de que a demanda institucional pode ter fatores comuns. A referência metodológica usada no projeto é Artes and Barroso (2023). Empiricamente, o PCA é estimado apenas na janela de treino para evitar vazamento de informação.

Redes neurais em grafo são mencionadas como possibilidade metodológica, com referência introdutória em Sanchez-Lengeling et al. (2021). A motivação é direta: se fundos

de uma gestora estão conectados a outros fundos por relações de cotas, então a exposição de uma gestora pode depender não apenas de seu próprio histórico, mas também da vizinhança no grafo. Neste estágio, o trabalho implementa baselines lineares, PCA/fatores e uma primeira feature de rede. O passo metodológico natural é transformar essa estrutura em um modelo de previsão por grafo, no qual nós representam fundos ou gestoras e arestas representam posições fundo→fundo.

2.4 Plataformas de investimento

O working paper *Replicant Investment Platforms*, do Prof. Maurício Ferraresi Junior (Ferraresi Junior, 2024), é mantido como referência provisória a confirmar. Ele é relevante para a interpretação de plataformas e vasos de investimento entre fundos, exatamente o tipo de estrutura que a CDA permite observar empiricamente. Como a citação exata ainda precisa ser confirmada, este eixo fica tratado com cautela.

Capítulo 3

Metodologia e Dados

3.1 Bases do núcleo empírico

O núcleo do trabalho usa três bases públicas da CVM e uma base auxiliar de preços da B3:

CONS. A composição consolidada de carteiras tem granularidade fundo $\times$ mês $\times$ ativo. No período 2016–2021, a amostra tratada contém aproximadamente 21,1 milhões de linhas. A base é 100% classificada como “Ações”, porque a consolidação da CVM dissolve cotas de fundos em ativos finais. Os valores de `Valor_Ativo_mil` estão em formato americano, com ponto decimal e eventual notação científica.

SH. A série histórica dos fundos tem granularidade fundo $\times$ dia e traz informações de gestora, classificação, nome do fundo e patrimônio líquido. O PL vem em formato brasileiro e é convertido para número com parser específico.

CDA Bloco 2. A Composição e Diversificação das Aplicações (CDA) informa posições de fundos em cotas de outros fundos. O Bloco 2 é usado para reconstruir arestas fundo $\rightarrow$ fundo. Essa base é necessária para a camada de rede do sistema preditivo, pois a CONS, ao consolidar a carteira, mostra o ativo final mas não preserva a trajetória FIC/master.

B3/COTAHIST. A CONS não informa quantidade de ações. Para converter a posição em ITUB4 de valor para quantidade estimada, usa-se o fechamento diário oficial da B3/COTAHIST, mercado à vista (TPMERC=010), selecionando o último pregão de cada mês. A amostra de preços cobre os 72 meses entre janeiro de 2016 e dezembro de 2021, sem lacunas mensais.

A ligação entre CONS e SH é feita por `Código` (CONS) igual a `COD_FUNDO` (SH), mantendo o mesmo CNPJ e a mesma data de competência mensal. A revisão de qualidade encontrou apenas 2 fundos-mês da CONS sem correspondência no SH.

3.2 Tratamentos de dados

Os principais tratamentos são:

- normalização de CNPJ para dígitos;
- parser separado para números em formato americano (CONS) e dinheiro em formato brasileiro (SH);
- remoção de linhas exatamente duplicadas na CONS, definidas por mesmo CNPJ, código, data, ativo e valor;
- extração de ticker terminal a partir do nome do ativo;
- classificação das variantes de exposição em direta, cedida e obrigação;
- consolidação de gestoras por grupo econômico via regras de texto;
- conversão de R\$ para US\$ com PTAX de fim de mês (BCB SGS série 1);
- reconstrução da rede fundo→fundo com a CDA Bloco 2;
- conversão auxiliar de valor de ITUB4 para quantidade estimada de ações com fechamento mensal B3/COTAHIST;
- construção de deltas mensais apenas quando os meses são consecutivos.

A duplicata exata da CONS é um ponto importante. A revisão profunda encontrou cerca de 0,2% de linhas exatamente repetidas, com impacto de aproximadamente 0,01% nos totais. A correção preserva lotes legítimos com valores diferentes e remove apenas cópias idênticas.

3.3 Definição de exposição

Para ITUB4, há três definições:

- **direta**: apenas a linha direta do ativo;
- **long**: direta mais ações cedidas em empréstimo;
- **net**: long mais obrigações por ações recebidas em empréstimo, que entram negativas.

A definição principal é *net*. No período, a soma das posições mensais em ITUB4 é R\$ 468 bi na definição direta, R\$ 540 bi na definição long e R\$ 496 bi na definição net. A definição net gera 264 observações gestora-mês com posição líquida negativa, evidenciando a relevância do aluguel de ações.

3.4 Rede de fundos e problema preditivo

A motivação de rede vem do fato de que fundos de cotas podem investir em outros fundos. Nesses casos, a exposição de uma gestora a uma ação pode refletir posições diretas de seus fundos, posições indiretas via fundos investidos e conexões com outras estruturas. A CDA Bloco 2 permite reconstruir essas conexões como um grafo direcionado, em que a aresta $A \rightarrow B$ significa que o fundo A detém cotas do fundo B.

O problema preditivo pode ser escrito em três níveis. No nível básico, para cada gestora g , ação i e mês t , observa-se a exposição $E_{g,i,t}$ e sua variação $\Delta E_{g,i,t}$. No nível de mercado, o conjunto das demais gestoras, $-g$, resume o comportamento do restante do mercado naquela ação. No nível de rede, as arestas da CDA informam quais fundos ou gestoras estão próximos no grafo. O sistema de previsão, portanto, procura usar:

$$\hat{E}_{g,i,t+1} = f(E_{g,i,\leq t}, E_{-g,i,\leq t}, G_t),$$

em que G_t é o grafo fundo-sobre-fundo observado no mês t .

Neste estágio, o trabalho implementa baselines transparentes: *random walk*, AR, modelos de painel, PCA/fatores e uma primeira feature de rede baseada na exposição de vizinhos. A formulação por GNN é o próximo passo natural: ela permitiria aprender pesos a partir do grafo, em vez de impor manualmente uma média de vizinhos.

3.5 Quantidade estimada de ações

Para estudar demanda em sentido estrito, valor monetário não é suficiente. A posição em reais varia tanto por compra e venda de ações quanto por variação de preço. Como a CONS não traz número de ações, a quantidade é estimada por:

$$q_{g,t}^{ITUB4} = \frac{V_{g,t}^{ITUB4} \times 1000}{P_t^{ITUB4}},$$

em que $V_{g,t}^{ITUB4}$ é a posição em `Valor_Ativo_mil` e P_t^{ITUB4} é o fechamento de ITUB4 no último pregão do mês na B3/COTAHIST. A multiplicação por 1000 converte o valor da CONS de mil reais para reais.

A mesma regra é aplicada às variantes direta, cedida e obrigação. Assim:

$$q^{dir} = \frac{1000V^{dir}}{P}, \quad q^{long} = \frac{1000(V^{dir} + V^{ced})}{P}, \quad q^{net} = \frac{1000(V^{dir} + V^{ced} + V^{obrig})}{P}.$$

Aqui, *dir*, *ced* e *obrig* indicam, respectivamente, posição direta, ações cedidas em empréstimo e obrigações por ações recebidas em empréstimo. A definição principal permanece *net*. A validação numérica reconstrói o valor original por $q_{g,t}^{ITUB4} P_t^{ITUB4} / 1000$ com erro máximo de aproximadamente $9,3 \times 10^{-10}$ mil reais, isto é, apenas erro de arredondamento de máquina.

Essa quantidade deve ser lida como robustez e não como substituta da exposição em valor. Ela é a melhor aproximação possível com CONS+B3 para separar efeito de preço de mudança aproximada de demanda, mas eventos societários que alterem mecanicamente o número de ações exigem cautela na interpretação temporal. A medida principal do TCC permanece a exposição em valor, por ser mais direta para risco patrimonial e gerenciamento de risco.

3.6 Unidade de análise

A unidade principal é a gestora consolidada por grupo econômico. Essa decisão torna a análise mais legível e reduz ruído de variações de nomes jurídicos. O painel ITUB4 tem 2.835 observações gestora-mês, cobrindo 42 grupos econômicos e 72 meses.

3.7 Avaliação preditiva

As previsões usam origem móvel com janela expansível. Em cada origem, o modelo é estimado apenas com dados até o mês t e prevê $t + h$. O benchmark é o *random walk*: para a variação, a previsão é $\hat{\Delta} = 0$; para o nível, a previsão é $\hat{y}_{t+h} = y_t$.

As métricas são RMSE, MAE, *skill* contra o *random walk* e acerto de direção. PCA e fatores são estimados somente na janela de treino, sem usar informação futura. A análise em valor é a especificação principal; a análise em quantidade estimada é uma robustez para ITUB4.

Capítulo 4

Resultados

4.1 Exposição e quantidade em ITUB4

O painel mostra que Itaú, Bradesco, BB, Kapitalo e Santander estão entre as maiores exposições médias a ITUB4. A Figura 4.1 resume a exposição em valor, enquanto a Figura 4.2 mostra a quantidade estimada de ações. A diferença entre as duas figuras é substantiva: a primeira mistura preço e quantidade; a segunda isola a aproximação de demanda.




Figura 4.1: Posição em ITUB4 por gestora (US\$ milhões, exposição net).




Figura 4.2: Quantidade estimada de ITUB4 por gestora (milhões de ações, exposição net).

Tabela 4.1: Definições de exposição em ITUB4: valor e quantidade estimada.

Def.	Valor (R\$ bi)	Média (US\$ mi)	Qtd. (bi ações)	Qtd. neg.
direta	468	39,0	14,77	0
long	540	45,1	17,02	0
net	496	41,4	15,71	264

4.2 Extensão para todas as ações

A extensão para todas as ações reconhece 836 tickers e produz um painel gestora $\times$ mês $\times$ ticker. O resultado mais importante do núcleo CONS+SH é a concentração: as ações detidas pelo maior número de gestoras são *blue chips* como VALE3, PETR4, ITUB4, BBDC4 e EQTL3. Isso sustenta a conexão com fragilidade por propriedade comum.




Figura 4.3: Ações detidas pelo maior número de gestoras.

4.3 Rede fundo-sobre-fundo e duplicação

A CDA Bloco 2 reconstrói 835.694 arestas fundo→fundo no período 2016–2021. A primeira pergunta de risco é se existem estruturas circulares. No subgrafo dos fundos observados no universo empírico, a resposta é negativa: todos os 72 meses são DAGs. Ou seja, não encontramos ciclos diretos que fariam um FIC retornar ao próprio caminho de investimento. Ao mesmo tempo, há aninhamento relevante: a profundidade máxima tem mediana 7 e máximo 9 níveis.

Tabela 4.2: Estrutura da rede CDA no universo observado.

Métrica	Valor
Arestas CDA processadas	835.694
Meses analisados	72
Meses com ciclos	0
Profundidade máxima mediana	7
Profundidade máxima observada	9
Nós no último mês	2.565
Arestas no último mês	5.968

A segunda pergunta é quanto a soma de fundos da mesma gestora duplica exposição. Para ITUB4, a exposição bruta intra-gestora soma R\$ 496,5 bi ao longo dos meses; após remover a parcela indireta estimada via relações FIC/master da própria gestora, a exposição cai para R\$ 309,8 bi. A duplicação interna estimada é 37,6%. No caso do Itaú, a duplicação média é 41,7%.




Figura 4.4: Itaú: exposição bruta e de-duplicada em ITUB4.

4.4 Previsão da variação mensal

Nas primeiras rodadas de forecasting, o alvo era a variação mensal da posição em US\$ para ITUB4. O resultado já era negativo e informativo: AR, média e PCA não superavam o *random walk*. Ao refazer o exercício em quantidade estimada de ações, como robustez para separar preço e quantidade, a conclusão se mantém. O melhor modelo, AR encolhido, melhora apenas 0,6% no RMSE e piora no MAE. A direção fica em torno de 50%.

Tabela 4.3: Variação mensal da quantidade estimada de ITUB4: *skill* contra random walk.

Modelo	RMSE (mi ações)	Skill RMSE	Skill MAE	Direção
Random walk	5,42	0,0%	0,0%	–
AR encolhido	5,39	+0,6%	-0,9%	50,4%
AR	5,49	-1,2%	-4,9%	50,4%
PCA $k = 1$	6,29	-16,1%	-13,0%	50,0%
PCA $k = 3$	6,19	-14,2%	-25,8%	50,4%




Figura 4.5: *Skill* de RMSE para a variação mensal da quantidade estimada de ITUB4.

A leitura é que a variação mensal, tanto em valor quanto em quantidade aproximada, é difícil de prever com modelos lineares simples. Esse resultado não encerra a pergunta; ele motiva usar informação adicional de mercado e de rede.

4.5 Previsão do nível e reversão à média

Ao mudar o alvo para o nível da posição em valor, aparece previsibilidade. Para ITUB4, o AR individual reduz o RMSE em cerca de 10% contra o *random walk* nos horizontes de 1 e 3 meses. O modelo de painel melhora em horizontes mais longos, chegando a 9% no horizonte de 6 meses. Esse resultado é relevante para risco patrimonial, mas não deve ser interpretado automaticamente como previsibilidade de compras e vendas de ações.




Figura 4.6: *Skill* contra random walk no nível, por alvo e horizonte.

Como robustez, quando o alvo é o nível da quantidade estimada de ações, a evidência é mais fraca. O AR individual melhora o RMSE em 3,5% no horizonte de um mês, mas perde para o *random walk* em três e seis meses. O modelo de painel também não melhora a previsão. Portanto, a reversão em valor é mais forte do que a reversão em quantidade.




Figura 4.7: *Skill* contra random walk no nível da quantidade estimada de ITUB4.

O refinamento de meia-vida estima explicitamente a velocidade de retorno à alocação-alvo. Para a posição em US\$ de ITUB4, 36 de 37 gestoras revertem à média; o coeficiente ρ mediano é aproximadamente 0,77 e a meia-vida mediana é 2,8 meses. Para a quantidade estimada, 33 de 37 gestoras revertem; o ρ mediano sobe para aproximadamente 0,83, a meia-vida mediana vai para 3,8 meses e a meia-vida de painel chega a 6,0 meses. Isso sugere que a demanda em ações é mais persistente e menos previsível do que a exposição em valor.




Figura 4.8: Meia-vida da reversão à alocação-alvo em ITUB4.




Figura 4.9: Meia-vida da reversão da quantidade estimada de ITUB4.

4.6 Generalização do forecasting

A rodada com todas as ações, ainda em valor, mostra que a previsibilidade do nível não é geral. Entre 238 ações elegíveis, a mediana da *skill* é negativa e apenas uma parcela pequena supera o *random walk*. ITUB4 fica entre as melhores, com *skill* próxima de 9,9%, ao lado de outras ações muito líquidas e amplamente detidas. Essa evidência deve ser lida como resultado de exposição patrimonial; a generalização para quantidade exigiria baixar e validar preços mensais para todos os tickers.




Figura 4.10: Distribuição da *skill* AR vs random walk por ação. Linha vermelha: ITUB4.

4.7 Rede como preditor complementar

Uma especificação complementar adiciona a exposição dos vizinhos no grafo CDA como preditor do nível da posição. O resultado não melhora o baseline de reversão à média: AR1 de painel tem *skill* de 3,3%, enquanto o modelo com rede tem 3,1%. Esse resultado deve ser lido com cautela. Ele não descarta o uso de redes; mostra apenas que uma feature manual simples, baseada em média de vizinhos, não basta para superar o AR de painel. O próximo passo coerente com a motivação do trabalho é formular um modelo de grafo mais expressivo, em que a rede CDA e o comportamento do restante do mercado sejam usados conjuntamente para prever exposição por gestora e por ação.

Capítulo 5

Conclusão

O projeto entrega cinco conclusões principais. Primeiro, é possível construir um painel mensal coerente de exposição das gestoras a ações usando CONS e SH, com tratamento cuidadoso de formato numérico, empréstimos de ações, grupos econômicos, R\$ e US\$. Segundo, a CDA Bloco 2 é a base adequada para recuperar a rede fundo→fundo que a CONS apaga ao consolidar carteiras. Terceiro, essa rede não apresenta ciclos no período analisado, mas tem aninhamento relevante e gera duplicação intra-gestora material. Quarto, a variação mensal da exposição é difícil de prever com modelos lineares simples; o *random walk* é um benchmark forte. Quinto, o nível da exposição em valor apresenta alguma reversão à média, especialmente em ITUB4, mas a quantidade estimada mostra que parte dessa reversão patrimonial não deve ser confundida com compra e venda previsível de ações.

A interpretação econômica é alinhada à literatura de demanda por ações. Carteiras observadas revelam demanda institucional e permitem estudar quem aumenta ou reduz exposição em cada ação. Ao mesmo tempo, a estrutura de fundos interconectados adiciona uma dimensão de risco: a exposição final não depende apenas da gestora isolada, mas também de como seus fundos estão ligados a outros fundos. Portanto, o caminho natural do TCC é um sistema de previsão de exposição por gestora e ação, usando histórico próprio, restante do mercado e rede fundo-sobre-fundo.

O resultado negativo da feature manual de rede não fecha a questão. Ele funciona como baseline: uma média de vizinhos não acrescenta sinal suficiente, mas um modelo de grafo mais flexível ainda é metodologicamente coerente com o problema. A próxima etapa é formalizar essa previsão em painel gestora $\times$ ação $\times$ mês, com features de mercado e de rede, e comparar o ganho preditivo contra *random walk*, AR e fatores.

Apêndice A

Apêndice: CDA e Estruturas Fundo-Sobre-Fundo

A.1 Por que a CDA aparece no projeto

A CONS é consolidada: ela mostra os ativos finais da carteira, mas apaga relações entre fundos. Se um FIC investe em um master que detém ações, a CONS mostra a exposição final em ações. Isso é ótimo para medir exposição, mas insuficiente para estudar a estrutura fundo→fundo. A CDA Bloco 2 entra para reconstruir essa rede, que é a base natural para modelos de previsão via grafos.

A.2 O que é a CDA Bloco 2

A CDA é a Composição e Diversificação das Aplicações dos fundos. O Bloco 2 registra cotas de fundos de investimento. As colunas relevantes usadas no projeto são:

- CNPJ_FUNDO: fundo que detém cotas;
- CNPJ_FUNDO_COTA: fundo investido;
- DT_COMPTC: data de competência;
- VL_MERC_POS_FINAL: valor de mercado da posição;
- DT_CONFID_APLIC: campo associado à confidencialidade de aplicação.

Nos arquivos históricos processados, DT_CONFID_APLIC aparece preenchido em 32,3% das arestas, mas CNPJ_FUNDO_COTA está disponível e destino vazio é zero. Portanto, o projeto não trata esse campo como sinônimo de destino mascarado.

A.3 Construção da base

O script `R/10_build_cda_edges.R` lê os ZIPs históricos da CVM, seleciona o arquivo `cda_fi_BLC_2_AAAA.csv`, normaliza os CNPJs e filtra arestas cuja origem está no universo

de fundos observado na SH. A saída é `data/processed/cda_edges.csv`, com 835.694 arestas em 72 meses.

Tabela A.1: Resumo da CDA processada.

Ano	Arestas	DT_CONFID	Destino no universo	Destino externo
2016	100.824	22.079	34.212	66.612
2017	105.717	31.805	35.024	70.693
2018	115.763	38.549	38.215	77.548
2019	133.670	50.980	44.651	89.019
2020	166.317	59.650	55.406	110.911
2021	213.403	67.105	67.389	146.014

A.4 Validação da CDA

As principais checagens foram:

- não há *self-loops*, isto é, fundo investindo diretamente nele mesmo;
- não há duplicatas exatas de arestas;
- os valores de mercado não têm NAs nem valores negativos;
- a fração $\phi = \text{valor}/PL_{\text{destino}}$ tem mediana próxima de 0,007;
- 98,6% das observações com PL válido ficam em $(0, 1]$.

Casos com $\phi > 1$ são raros e foram capados em 1 no cálculo de de-duplicação. Isso é conservador: impede que erro de unidade ou defasagem de PL gere propriedade acima de 100%.

A.5 De-duplicação intra-gestora

Se o fundo A de uma gestora investe no fundo B da mesma gestora, e B tem exposição L_B a uma ação, parte de L_B pode aparecer duas vezes quando somamos fundos da gestora. A fração de B detida por A é:

$$\phi_{A \rightarrow B} = \frac{v_{A \rightarrow B}}{PL_B}.$$

Assim, a exposição de-duplicada por gestora é:

$$\text{dedup}_g = \sum_{i \in g} L_i - \sum_{A \rightarrow B \in g} \phi_{A \rightarrow B} L_B.$$

Para ITUB4, a duplicação intra-gestora estimada é 37,6%. Se também forem consideradas arestas entre gestoras no universo observado, a duplicação rastreável aumenta em cerca de 5,3 pontos percentuais, chegando a 43,0%. Portanto, o número de 37,6% deve sempre ser lido como duplicação *intra-gestora*, não como duplicação total do sistema.

A.6 Resultados da rede CDA

No módulo CDA, o grafo observado é acíclico nos 72 meses e tem profundidade relevante: a cadeia máxima tem mediana 7 e máximo 9 níveis. A extensão para todas as ações sugere duplicação intra-gestora próxima de 37% também em *blue chips*. Esses achados sustentam a motivação de risco: fundos sobre fundos podem ampliar exposição econômica e criar camadas relevantes de interconexão, mesmo sem circularidade.

A.7 Limitações da CDA

A CDA tem três limitações principais:

1. ela mede relações de cotas de fundos, não exposição final em ações; por isso deve ser usada junto com a CONS, não em substituição a ela;
2. muitos destinos estão fora do universo CONS+SH usado no painel principal, o que limita a cobertura de rede observável;
3. a interpretação de DT_CONFID_APLIC exige cautela e não deve ser descrita como destino mascarado quando o CNPJ do destino está preenchido.

Assim, a CDA deve ser tratada como infraestrutura de rede: essencial para estudar fundos sobre fundos, mas dependente de filtros, cobertura e validações próprias. O apêndice documenta esses detalhes para que a camada de grafo seja auditável.

Referências Bibliográficas

- Rinaldo Artes and Lúcia Pereira Barroso. *Métodos Multivariados de Análise Estatística*. Blucher, São Paulo, 2023. ISBN 9786555067026.
- B3 S.A. — Brasil, Bolsa, Balcão. Cotações históricas — cotahist. <https://bvmf.bmfbovespa.com.br/InstDados/SerHist/>, 2024.
- Maurício Ferraresi Junior. Replicant investment platforms. Working paper. Citação bibliográfica exata a confirmar com o orientador., 2024.
- Xavier Gabaix and Ralph S. J. Koijen. In search of the origins of financial fluctuations: The inelastic markets hypothesis. NBER Working Paper 28967, National Bureau of Economic Research, 2021. <https://www.nber.org/papers/w28967>.
- Robin Greenwood and David Thesmar. Stock price fragility. *Journal of Financial Economics*, 102(3):471–490, 2011.
- Ralph S. J. Koijen and Motohiro Yogo. A demand system approach to asset pricing. *Journal of Political Economy*, 127(4):1475–1515, 2019. doi: 10.1086/701683.
- Benjamin Sanchez-Lengeling, Emily Reif, Adam Pearce, and Alexander B. Wiltschko. A gentle introduction to graph neural networks. *Distill*, 2021. <https://distill.pub/2021/gnn-intro/>.