

FUNDAÇÃO GETULIO VARGAS
ESCOLA DE ECONOMIA DE SÃO PAULO (EESP)

Forecasting da exposição de gestoras de ações e o risco de estruturas fundo-sobre-fundo

Validação das bases, pipeline de exposição e plano de previsão
(piloto: ITUB4 — Itaú Unibanco PN, 2016–2021)

João Paulo Zangrandi

Orientador: Prof. Maurício Ferraresi Junior

São Paulo
14 de junho de 2026

Resumo

Este documento consolida a fase de *construção e validação de dados* de um trabalho que busca medir e inferir o risco de estruturas “fundo-sobre-fundo” no mercado brasileiro de fundos, usando como lente a exposição das gestoras a ações. A motivação teórica vem do *demand-based asset pricing* (Kojen and Yogo, 2019; Gabaix and Kojen, 2021): se a demanda dos investidores institucionais tem estrutura (inércia, co-movimento), ela é em parte previsível, e estruturas aninhadas de fundos podem amplificar ou propagar choques (Greenwood and Thesmar, 2011). Validamos o método com uma única ação, **ITUB4**, no período 2016–2021. A partir das bases públicas da CVM (composição de carteiras consolidada, “CONS”, e série histórica, “SH”), construímos um *pipeline* modular em R que mede a exposição em **valor** (em R\$ e em US\$), na definição **net** (direta + cedida em empréstimo + obrigações; também reportada como **direta** e **long**), consolidando entidades do mesmo grupo econômico e mantendo os fundos de cotas (FIC). Todas as afirmações sobre as bases foram verificadas contra os arquivos reais; reportamos cada diagnóstico e as discrepâncias encontradas. O painel final tem 2.835 observações gestora-mês (42 grupos econômicos, 72 meses). Documentamos ainda a **limitação crítica** de que a base CONS é integralmente consolidada em ações — o que apaga as relações fundo→fundo — e o plano para obter a base não consolidada (CDA, Bloco 2: cotas de fundos) e montar o grafo fundo-sobre-fundo. Os modelos de previsão (PCA/análise fatorial e GNN) estão apenas *planejados*; nenhum foi executado nesta fase.

Palavras-chave: demand-based asset pricing; fundos de investimento; fundos de cotas; exposição em ações; risco sistêmico de redes; CVM.

Abstract

This report consolidates the *data construction and validation* phase of a project that measures and infers the risk of “fund-of-funds” structures in the Brazilian fund market, using equity asset managers’ exposure as a lens. The theoretical motivation comes from demand-based asset pricing (Kojen and Yogo, 2019; Gabaix and Kojen, 2021): if institutional demand has structure, it is partly predictable, and nested fund structures may amplify or propagate shocks (Greenwood and Thesmar, 2011). We validate the method with a single stock, ITUB4, over 2016–2021. From the Brazilian regulator’s (CVM) public datasets we build a modular R pipeline measuring exposure in value (BRL and USD), in a net definition (direct + lent + borrowed obligations), consolidating economic groups and keeping feeder funds (FIC). Every claim about the data was verified against the raw files. The final panel has 2,835 manager-month observations (42 economic groups, 72 months). We document the critical limitation that the consolidated dataset dissolves fund-to-fund links, and the plan to obtain the non-consolidated dataset (CDA, Block 2: fund quotas) to build the fund-of-funds graph. Forecasting models (PCA/factor analysis and GNNs) are only planned; none were run.

Sumário

Resumo	1
Abstract	1
1 Introdução e motivação	3
2 Revisão bibliográfica	3
3 As bases de dados	4
3.1 CONS — composição consolidada de carteiras	4
3.2 SH — série histórica	4
3.3 Ligação entre as bases e grupos econômicos	4
4 Decisões metodológicas	4
5 O pipeline, passo a passo	5
6 Diagnósticos e validação	5
7 Resultados descritivos da exposição	7
8 Limitação crítica e o grafo fundo-sobre-fundo	9
9 Plano de previsão (não executado)	10
10 Conclusão e próximos passos	10

1 Introdução e motivação

O objeto central deste trabalho é o **risco das estruturas “fundo-sobre-fundo”**: fundos de cotas (FIC) que investem em outros fundos que, por sua vez, detêm ações. A **lente** para enxergá-lo é a **exposição das gestoras a ações**. Para validar todo o método antes de estendê-lo, fixamos uma única ação, **ITUB4** (Itaú Unibanco PN), no período **2016–2021** (dados mensais de carteiras).

A motivação teórica vem do *demand-based asset pricing*. Koijen and Yogo (2019) propõem um sistema de demanda em que os preços se formam pela demanda dos investidores institucionais, e não apenas por fundamentos; Gabaix and Koijen (2021) argumentam que o mercado agregado é inelástico, de modo que fluxos têm impacto desproporcional sobre preços. Se a demanda das gestoras tem estrutura — inércia, contágio, co-movimento — então (i) ela é em parte *previsível* e (ii) as estruturas aninhadas de fundos podem *amplificar ou propagar* choques. Greenwood and Thesmar (2011) formalizam como a estrutura de propriedade (*ownership*) gera “fragilidade de preços”: ativos detidos por investidores sujeitos a choques correlacionados ficam mais voláteis. Daí o interesse em medir “participações sobre participações” para inferir o risco dessas estruturas.

Esta fase entrega: (a) a validação rigorosa das bases; (b) um *pipeline* reproduzível que produz o painel de exposição; (c) os diagnósticos com resultados reais; e (d) o plano para as próximas etapas (grafo fundo-sobre-fundo e previsão). **Nenhum modelo de previsão foi executado.**

2 Revisão bibliográfica

Demand-based asset pricing. Koijen and Yogo (2019) estimam um sistema de demanda por ativos a partir das carteiras de investidores institucionais e mostram que características e demanda explicam preços e suas variações. Gabaix and Koijen (2021) (a “hipótese dos mercados inelásticos”) quantificam a baixa elasticidade-preço da demanda agregada e o efeito amplificado de fluxos.

Propriedade comum e fragilidade de preços. Greenwood and Thesmar (2011) introduzem medidas de fragilidade baseadas na concentração e na correlação da propriedade; a intuição transita diretamente para o nosso problema, em que a sobreposição de carteiras entre gestoras (e a duplicação via FIC) pode concentrar risco.

Métodos. Para os fatores latentes de demanda usaremos análise de componentes principais e análise fatorial, seguindo Artes and Barroso (2023, cap. 3 e 4). Para modelar a rede de gestoras/fundos como grafo, a referência introdutória é Sanchez-Lengeling et al. (2021).

Plataformas e o paper do orientador. A referência central do orientador é o working paper *Replicant Investment Platforms* (Ferraresi Junior, 2024), que trata plataformas de investimento como unidade de análise sob o arcabouço de demanda. **A citação bibliográfica exata será confirmada com o orientador** (mantida aqui como entrada provisória, para não se inventar dados bibliográficos).

3 As bases de dados

Usamos duas bases públicas da CVM, uma por ano (2016–2021), ambas com separador “;” e codificação UTF-8.

3.1 CONS — composição consolidada de carteiras

Granularidade fundo $\times$ mês $\times$ ativo. Colunas relevantes: `CNPJ`, `Código`, `Tipo_Ativo`, `Data_Competência`, `Nome_Ativo`, `Valor_Ativo_mil`. A data de competência é fim de mês (AAAA-MM-DD). Os valores estão em **formato americano** (ponto decimal, inclusive notação científica, p.ex. 6.37E-4); o *parse* é direto, sem remoção de separador. Confirmamos que a base é **100% “Ações”** — ou seja, a consolidação da CVM já dissolveu as cotas de fundos em ações (Seção 8).

Há **três variantes** de ITUB4 em `Nome_Ativo`, todas com `Tipo_Ativo` = “Ações”, que identificamos de forma robusta pelo *ticker* terminal e classificamos por palavra-chave (Tabela 2): posição *direta*; ações *cedidas* em empréstimo (ainda são exposição do fundo); e *obrigações* por ações recebidas em empréstimo (aluguel tomado, valor negativo).

3.2 SH — série histórica

Granularidade fundo $\times$ dia. Traz a **GESTORA** e o **patrimônio líquido (PL)** de cada fundo — a informação ausente na CONS. O PL está em **formato brasileiro** (R\$ 49.749,57): removemos “R\$” e o ponto de milhar e trocamos a vírgula decimal por ponto. A data é diária (dd/mm/aaaa).

3.3 Ligação entre as bases e grupos econômicos

A junção é por fundo: `Código (CONS) = COD_FUNDO (SH)` para o mesmo CNPJ. Como a CONS é mensal e a SH é diária, restringimos a SH às datas de competência da CONS. Por fim, consolidamos entidades do mesmo grupo econômico em uma única gestora (Itaú, BTG Pactual, XP, Caixa, Credit Suisse, BNP Paribas, JGP etc.) por casamento de expressões regulares sobre o nome normalizado, gerando uma tabela de revisão (`audit_gestora_group_map.csv`).

4 Decisões metodológicas

As decisões abaixo foram travadas com o orientador.

1. **Unidade:** gestora, consolidada por grupo econômico.
2. **Medida em valor, não quantidade, em R\$ e em US\$.** A conversão usa a PTAX de fim de mês (BCB, SGS série 1) (Banco Central do Brasil, 2024). Modelar a posição em valor é mais intuitivo para o leitor do que por quantidades.

3. **Exposição** medida em **três definições, geradas em paralelo**: direta (apenas a linha “ITAUUNIBANCO PN N1 - ITUB4”), **long** (= direta + cedida em empréstimo) e **net** (= long + obrigações, que entram negativas). O painel **primário é a net** (o empréstimo é material), mas as três são exportadas (`painel_itub4_{direta,long,net}.csv`) para comparação de robustez (Seção 7).
4. **Estacionariedade**: o alvo primário é a **posição** (em nível, não-estacionária $\Rightarrow$ diferenciar) e sua variação mensal. O **peso** (posição/PL) *não* é diferenciado, para evitar autocorrelação espúria. Reportamos o teste ADF (Seção 6).
5. **Manter os FIC**: a estrutura aninhada é o objeto de estudo, não ruído. A duplicação direta/ indireta é tolerada e diagnosticada; o que preocupa são as estruturas circulares (só detectáveis com a base da Seção 8).
6. **Deltas “gap-safe”**: variações calculadas apenas entre meses consecutivos.

5 O pipeline, passo a passo

O código está em R/, modular e orquestrado por `R/99_run_all.R`:

- `00_config.R` — parâmetros (diretório dos dados, anos, ticker, modo de exposição, grupos).
- `01_utils.R` — *parsers* (número americano, monetário brasileiro), normalização de CNPJ, extração de *ticker* por regex e classificação de variante.
- `02_load_cons.R` / `03_load_sh.R` — carga ano a ano com `gc()`; retornam apenas *extracts* leves (os $\sim 4,2$ GB brutos são descartados a cada ano).
- `04 Consolidate groups.R` — consolidação robusta de grupos + tabela de revisão.
- `05_build_panel.R` — posição net em R\$ e US\$, peso descritivo, deltas *gap-safe* e ADF.
- `06_diagnostics.R` — valida os fatos das bases e escreve as auditorias.
- `07_correlation.R` — matrizes de correlação entre gestoras + figuras.
- `forecasting_scaffold.R` — esqueleto de PCA/AR/VAR/GNN, **não executado**.

O *ticker* é parametrizado: o pipeline é genérico para qualquer ação, mas nesta fase foi testado apenas para ITUB4. Um *cache* dos *extracts* acelera reexecuções.

6 Diagnósticos e validação

Rodamos o pipeline sobre os arquivos reais e verificamos cada afirmação sobre as bases. A Tabela 1 resume; o relatório completo está em `outputs/tables/diagnostics_report.txt`.

Tabela 1: Validação dos fatos das bases (2016–2021), contra os dados reais.

Fato	Encontrado	Status
Cabeçalhos idênticos entre anos	CONS 9 colunas; SH 10 colunas	OK
CONS 100% “Ações”	100,0000% (1 tipo distinto)	OK
Magnitudes 2016 (net)	direta R\$ 35,4 bi; cedida R\$ 9,6 bi; obrig. –R\$ 5,8 bi	OK
Sinal das obrigações	negativo (total –R\$ 43,6 bi em 2016–2021)	OK
SH: gestoras / %FIC (2016)	50 gestoras; 52,6% das linhas são FIC	OK
SH: duplicata (data, fundo)	0 duplicatas	OK
Datas da CONS presentes no SH	72/72 (join por data exata é seguro)	OK
CNPJ da CONS presentes no SH	100,00%	OK
ITUB4 sem atribuição a gestora	0 fundos-mês	OK

Discrepância investigada (formato de número). Em 4 dos 6 anos o `fread` tipou `Valor_Ativo_mil` como texto. A causa *não* é vírgula decimal: são **22 linhas** (em ~21,1 milhões) com **aspas malformadas** no `Nome_Ativo` de “ações de companhia fechada”, que jogam texto na coluna de valor. **Nenhuma é ITUB4**; o *parser* robusto as converte em **NA** (impacto nulo). Isso *refina* a afirmação original “parse direto sem problemas”: o conteúdo numérico é, de fato, decimal americano. Ver `audit_cons_valor_nao_parseado.csv`.

Tabela 2: As três variantes de ITUB4 na CONS. Os valores são a *soma* no período 2016–2021.

Variante	Nome_Ativo	Linhas	Valor (R\$ b)
direta	ITAUNIBANCO PN N1 - ITUB4	98.290	468
cedida	Ações e outros TVM cedidos em empréstimo - ITUB4	64.461	71
obrigação	Obrigações por ações e outros TVM recebidos em empréstimo - ITUB4	42.418	–43

Cobertura e duplicação. Em média 74,7% dos fundos-mês da SH têm carteira na CONS no mesmo mês (o restante distingue “ausência = 0 real” de “NA”). Importante para o tema: **61,7%** dos fundos-mês que detêm ITUB4 são FIC com ITUB4 “direto” (após a consolidação da CVM) — isto é, a duplicação direta/indireta apontada pelo orientador é **material**. A mesma duplicação afeta o *denominador* do peso (somar os PLs de FIC e master conta o mesmo patrimônio duas vezes) — razão adicional para tratar o peso como descritivo e priorizar a posição.

Estacionariedade (ADF). Para as 40 gestoras com ≥ 24 meses (Tabela 3): a **posição em nível** é estacionária em apenas 6/40 (logo, majoritariamente não-estacionária — justifica diferenciar), enquanto a sua **primeira diferença** é estacionária em 37/40. O **peso** é estacionário em apenas 9/40: o ADF, com 72 observações, tem baixa potência e *não* confirma de forma ampla a hipótese de que o peso já seja estacionário. Ainda assim, seguindo a orientação (e para evitar autocorrelação espúria ao diferenciar uma razão limitada), mantemos o peso em nível como variável descritiva e modelamos a *posição em diferenças*.

Tabela 3: Teste ADF: n^o de gestoras (de 40) com $p < 0,05$ (rejeita raiz unitária).

Série	Estacionárias ($p < 0,05$)
Peso (posição/PL)	9/40
Posição em US\$ (nível)	6/40
Variação da posição em US\$ (1 ^a dif.)	37/40

7 Resultados descritivos da exposição

O painel final (`data/processed/painel_itub4.csv`) tem 2.835 observações gestora-mês, 42 grupos econômicos e 72 meses (jan/2016 a dez/2021). Como saneamento, o peso `peso_itub4` agora varia entre -6% e $+21\%$ (mediana $0,84\%$), com **zero** valores impossíveis — corrigindo uma versão anterior do painel em que o peso chegava a $\sim 5 \times 10^9$ por um erro de *parsing* (remoção do ponto decimal). A Tabela 4 lista as maiores gestoras por posição média em ITUB4 (US\$).

Tabela 4: Maiores gestoras por posição média mensal em ITUB4 (US\$ milhões, exposição net).

Gestora (grupo)	Posição média (US\$ milhões)
Itaú	499,5
Bradesco	185,2
BB	115,4
Kapitalo Investimentos	108,9
Santander	101,2
Occam Brasil	66,9
SPX Capital	54,6
BTG Pactual	42,4

Sensibilidade à definição de exposição. A Tabela 5 compara as três definições. A soma das posições mensais cresce de R\$468,3 bi (direta) para R\$540,1 bi (long, somando as cedidas) e recua para R\$496,5 bi na net (descontadas as obrigações). Sob a net, **264 de 2.835** observações gestora-mês (9,3%) ficam *net short* em ITUB4 (obrigações $>$ posições), o que nunca ocorre nas definições direta ou long — evidência de que o empréstimo é material e de que vale reportar ambas as visões. As figuras de posição e correlação são geradas para cada definição (sufixos `_direta/``_long`; abaixo, a net).

Tabela 5: Comparação das definições de exposição. “Soma” = total das posições mensais sobre as 2.835 observações gestora-mês (mesma convenção da Tabela 2); “média” = por gestora-mês.

Definição	Soma pos. mensais (R\$ bi)	Pos. média (US\$ milhões)	Obs. net short	Peso máx.
direta	468,3	39,0	0	21,0%
long	540,1	45,1	0	21,0%
net	496,5	41,4	264	21,0%

As Figuras 1 e 2 mostram a evolução da posição e a correlação entre gestoras da variação mensal da posição em US\$ (definição net) — esta última explicitamente pedida pelo orientador.




Figura 1: Posição em ITUB4 por gestora (US\$ milhões, exposição net).




Figura 2: Correlação entre gestoras da variação mensal da posição em ITUB4 (US\$).

8 Limitação crítica e o grafo fundo-sobre-fundo

A base CONS é **100% “Ações”**: a consolidação da CVM *apagou* as relações fundo→fundo (quem detém cotas de quem). Há uma ironia — a consolidação que facilita medir a exposição em ações é a que destrói a estrutura que queremos estudar. Portanto, a partir da CONS *não* é possível montar o grafo fundo-sobre-fundo, detectar estruturas circulares nem medir aninhamento.

Solução (localizada). A base **CDA não consolidada** da CVM (Comissão de Valores Mobiliários (CVM), 2024) preserva essas relações. Em particular, o **Bloco 2 — “Cotas de Fundos de Investimento”** mantém as linhas em que um fundo detém cotas de outro fundo. Os arquivos mensais estão em https://dados.cvm.gov.br/dados/FI/DOC/CDA/DADOS/cda_fi_ (cada ZIP contém o arquivo do bloco, *cda_fi_BLC_2_AAAAMM.csv*). Os nomes exatos das colunas que identificam o fundo investido (CNPJ/nome da cota) serão confirmados no Dicionário de Dados da CVM (não os inventamos aqui).

Desenho do grafo. Nó = fundo (CNPJ); aresta direcionada “detém cotas de”, ponderada pelo valor investido. Sobre esse grafo: (i) *detecção de ciclos* (estruturas circulares) com *igraph*; (ii) *profundidade de aninhamento* (distância FIC→master→ação); (iii) *peso indireto* (exposição look-through a uma ação via cotas). Essas métricas são o “coração”

do risco fundo-sobre-fundo e ligam-se ao painel de exposição já construído.

9 Plano de previsão (não executado)

Nenhum modelo foi rodado. O alvo é a variação mensal da posição em US\$ por gestora, avaliada *out-of-sample* com origem móvel. O arcabouço previsto compara:

1. **Baselines:** *random walk*, $AR(p)$ por gestora e VAR (com regularização, dado o número pequeno de gestoras).
2. **Fatores latentes de demanda:** PCA e análise fatorial (Artes and Barroso, 2023), estimados apenas na janela de treino para não vazar futuro, regredindo cada gestora nos k fatores.
3. **Grafo (GNN/temporal GNN):** usando a rede da Seção 8; referência introdutória Sanchez-Lengeling et al. (2021).

Métricas: RMSE/MAE *out-of-sample* e comparação entre modelos (p.ex. Diebold–Mariano).

10 Conclusão e próximos passos

Esta fase entregou um *pipeline* reproduzível e *validado contra os dados reais* para a exposição de gestoras a ITUB4 (em R\$ e US\$, net, com grupos consolidados e FIC mantidos), com diagnósticos completos e a correção de um erro de *parsing* que corrompia uma versão anterior do painel. Os próximos passos, *a pedido explícito*, são: (1) obter a base CDA (Bloco 2) e construir o grafo fundo-sobre-fundo; (2) estender o pipeline a todas as ações; (3) executar os modelos de previsão. Nada disso foi feito ainda.

Pontos a confirmar com o orientador. (i) citação exata de *Replicant Investment Platforms*; (ii) definição de exposição padrão (mantemos **net**); (iii) tratamento da duplicação via FIC à luz dos 61,7% observados.

Referências

- Rinaldo Artes and Lúcia Pereira Barroso. *Métodos Multivariados de Análise Estatística*. Blucher, São Paulo, 2023. ISBN 9786555067026.
- Banco Central do Brasil. Sistema gerenciador de séries temporais (sgs) — série 1, taxa de câmbio r\$/us\$ (ptax venda). <https://www3.bcb.gov.br/sgspub/>, 2024.
- Comissão de Valores Mobiliários (CVM). Composição e diversificação das aplicações (cda) — portal de dados abertos. <https://dados.cvm.gov.br/dataset/fi-doc-cda>, 2024.
- Maurício Ferraresi Junior. Replicant investment platforms. Working paper. Citação bibliográfica exata a confirmar com o orientador., 2024.
- Xavier Gabaix and Ralph S. J. Koijen. In search of the origins of financial fluctuations: The inelastic markets hypothesis. NBER Working Paper 28967, National Bureau of Economic Research, 2021. <https://www.nber.org/papers/w28967>.
- Robin Greenwood and David Thesmar. Stock price fragility. *Journal of Financial Economics*, 102(3):471–490, 2011.
- Ralph S. J. Koijen and Motohiro Yogo. A demand system approach to asset pricing. *Journal of Political Economy*, 127(4):1475–1515, 2019. doi: 10.1086/701683.
- Benjamin Sanchez-Lengeling, Emily Reif, Adam Pearce, and Alexander B. Wiltschko. A gentle introduction to graph neural networks. *Distill*, 2021. <https://distill.pub/2021/gnn-intro/>.