

FUNDAÇÃO GETULIO VARGAS
ESCOLA DE ECONOMIA DE SÃO PAULO (EESP)

Forecasting consolidado da exposição de gestoras a ações

Evidência do mercado brasileiro de fundos, 2016–2021

João Paulo Zangrandi

Orientador: Prof. Maurício Ferraresi Junior

São Paulo
18 de junho de 2026

Resumo

Este trabalho mede e prevê a exposição consolidada das gestoras brasileiras a ações, inspirado pela literatura de *demand-based asset pricing*. A unidade empírica central é gestora $\times$ mês $\times$ ação: para cada ação, observa-se mês a mês quais gestoras aumentaram ou reduziram exposição e testa-se se a exposição futura pode ser prevista a partir do histórico da própria gestora e do comportamento do restante do mercado, isto é, das demais gestoras. O núcleo empírico usa as bases CONS e SH da CVM para construir um painel consolidado de exposição em R\$ e US\$, por gestora e por ação, com validação inicial em ITUB4 e extensão para todos os tickers identificáveis.

O resultado central de dados é que a exposição institucional é concentrada em *blue chips*, exatamente os ativos em que a literatura de demanda e propriedade comum sugere maior relevância para preços e risco. No forecasting, modelos lineares e fatoriais mostram que a variação mensal é difícil de prever; já o nível da exposição em valor apresenta alguma reversão à média, especialmente em ações muito líquidas e amplamente detidas. A quantidade estimada de ITUB4, construída com preço B3/COTAHIST, entra como robustez para separar preço de quantidade. A CDA Bloco 2 não substitui esse núcleo consolidado: ela é tratada em apêndice técnico, com detalhe, para reconstruir a rede fundo $\rightarrow$ fundo apagada pela CONS, avaliar aninhamento, testar circularidade e fundamentar extensões futuras com modelos de grafo.

Palavras-chave: demand-based asset pricing; fundos de investimento; exposição em ações; forecasting; redes; CVM.

Sumário

Resumo	i
1 Introdução	1
2 Revisão Bibliográfica	3
2.1 Demand-based asset pricing	3
2.2 Fragilidade por propriedade comum	3
2.3 Métodos de previsão e fatores	3
2.4 Plataformas de investimento	4
3 Metodologia e Dados	5
3.1 Bases do núcleo empírico consolidado	5
3.2 Tratamentos de dados	5
3.3 Definição de exposição	6
3.4 Problema preditivo consolidado	6
3.5 Quantidade estimada de ações	7
3.6 Unidade de análise	7
3.7 Avaliação preditiva	7
4 Resultados	9
4.1 Exposição e quantidade em ITUB4	9
4.2 Extensão para todas as ações	10
4.3 Leitura complementar da rede	11
4.4 Previsão da variação mensal	11
4.5 Previsão do nível e reversão à média	12
4.6 Generalização do forecasting	14
4.7 Teste complementar com rede	15
5 Conclusão	16

A	Apêndice: CDA e Estruturas Fundo-Sobre-Fundo	17
A.1	Por que a CDA aparece no projeto	17
A.2	O que é a CDA Bloco 2	17
A.3	Por que uma leitura simples da CDA fica ruim	18
A.4	Construção da base processada	18
A.5	Validação da CDA	19
A.6	Visualização dos grafos	20
A.7	Ciclos e profundidade	21
A.8	De-duplicação intra-gestora	22
A.9	Como a CDA se conecta a modelos de grafo	23
A.10	Limitações da CDA	23

Capítulo 1

Introdução

O objetivo deste trabalho é medir e prever a exposição consolidada das gestoras brasileiras a ações. A pergunta empírica nasce de uma ideia simples: se investidores institucionais têm demandas persistentes por ativos, então carteiras observadas podem conter informação sobre comportamento futuro. A literatura de *demand-based asset pricing* fornece a motivação: preços não são determinados apenas por fundamentos agregados, mas também pela demanda de investidores com restrições, preferências e mandatos específicos (Kojien and Yogo, 2019; Gabaix and Kojien, 2021).

O caso brasileiro é adequado para esse exercício porque a CVM disponibiliza bases públicas de fundos. A CONS permite observar a composição consolidada das carteiras e a SH permite associar cada fundo à sua gestora e ao seu patrimônio líquido. Essas bases permitem medir exposição em valor, em R\$ e US\$, que é a medida mais direta de escala econômica e risco patrimonial. A previsão é feita de forma consolidada por gestora: para cada ação e mês, mede-se quem aumentou ou reduziu exposição; para cada gestora, usa-se seu próprio histórico e o comportamento das demais gestoras, o “restante do mercado” ou $n - 1$, para prever exposição futura.

A quantidade estimada de ações é construída para ITUB4 com o fechamento oficial mensal da B3 (B3 S.A. — Brasil, Bolsa, Balcão, 2024). Ela é mantida como robustez conceitual, pois ajuda a separar efeito de preço de mudança aproximada de quantidade, mas a medida principal de exposição do trabalho permanece em valor. A CDA Bloco 2, por sua vez, entra como apêndice técnico: a CONS é consolidada e apaga o caminho de fundos investindo em fundos; a CDA recupera esse caminho e permite visualizar a rede fundo→fundo. No desenho atual, não se prevê o grafo em si. O alvo da previsão é a exposição consolidada. A rede é uma forma de representar interconexões e uma possível camada futura de features ou modelos de grafo.

O trabalho responde a cinco perguntas:

1. Como medir a exposição das gestoras a ações em R\$ e US\$, com tratamento consistente de empréstimos de ações e grupos econômicos?
2. A exposição futura de uma gestora pode ser prevista a partir do próprio histórico e do restante do mercado?
3. A diferença entre exposição em valor e quantidade estimada muda a interpretação de demanda?

4. A evidência inicial de ITUB4 se generaliza para outras ações?
5. Como a rede fundo→fundo, reconstruída pela CDA em apêndice, qualifica a interpretação de risco e prepara uma extensão com modelos de grafo?




Figura 1.1: Desenho empírico: núcleo consolidado e apêndice de rede.

Assim, a CDA não entra como base alternativa à CONS. As duas têm funções diferentes. A CONS mede a exposição final em ações e sustenta o forecasting consolidado; a CDA recupera o caminho de fundos sobre fundos e documenta uma camada de rede que pode ser usada para risco, de-duplicação e extensões de graph learning. Os detalhes de tratamento da CDA ficam no Apêndice A.

Capítulo 2

Revisão Bibliográfica

2.1 Demand-based asset pricing

Koijen and Yogo (2019) propõem um sistema de demanda por ativos no qual investidores institucionais escolhem carteiras em função de características dos ativos, preços e restrições próprias. A contribuição central para este TCC é tratar carteiras observadas como revelação de demanda. Em vez de olhar apenas para retornos ou fundamentos agregados, o pesquisador usa a composição das carteiras para inferir como diferentes investidores demandam ativos.

Gabaix and Koijen (2021) desenvolvem a hipótese de mercados inelásticos: fluxos podem ter impacto desproporcional sobre preços quando a demanda agregada por ações não é altamente elástica. Para este trabalho, a implicação é direta: se gestoras concentram demanda nas mesmas ações e ajustam posições de forma correlacionada, variações de exposição podem ser relevantes para preços e risco.

2.2 Fragilidade por propriedade comum

Greenwood and Thesmar (2011) mostram que a estrutura de propriedade pode gerar fragilidade de preços. Ativos detidos por investidores sujeitos a choques semelhantes tendem a ficar mais vulneráveis, pois vendas ou compras correlacionadas podem amplificar movimentos. No nosso contexto, as ações *crowded*, detidas por muitas gestoras, são candidatas naturais a esse tipo de fragilidade.

2.3 Métodos de previsão e fatores

O uso de PCA e análise fatorial segue a lógica de que a demanda institucional pode ter fatores comuns. A referência metodológica usada no projeto é Artes and Barroso (2023). Empiricamente, o PCA é estimado apenas na janela de treino para evitar vazamento de informação.

Redes neurais em grafo são mencionadas como possibilidade metodológica, com referência introdutória em Sanchez-Lengeling et al. (2021). A motivação é direta: se fundos

estão conectados por relações de cotas, então essa estrutura pode ser transformada em uma matriz de adjacência e usada como informação para prever exposição. Ainda assim, o alvo deste TCC não é prever a topologia da rede. O alvo é a exposição consolidada por gestora e ação. A rede CDA é documentada como apêndice e como extensão metodológica possível.

2.4 Plataformas de investimento

O working paper *Replicant Investment Platforms*, do Prof. Maurício Ferraresi Junior (Ferraresi Junior, 2024), é mantido como referência provisória a confirmar. Ele é relevante para a interpretação de plataformas e vasos de investimento entre fundos, exatamente o tipo de estrutura que a CDA permite observar empiricamente. Como a citação exata ainda precisa ser confirmada, este eixo fica tratado com cautela.

Capítulo 3

Metodologia e Dados

3.1 Bases do núcleo empírico consolidado

O núcleo do trabalho usa duas bases públicas da CVM e uma base auxiliar de preços da B3:

CONS. A composição consolidada de carteiras tem granularidade fundo $\times$ mês $\times$ ativo. No período 2016–2021, a amostra tratada contém aproximadamente 21,1 milhões de linhas. A base é 100% classificada como “Ações”, porque a consolidação da CVM dissolve cotas de fundos em ativos finais. Os valores de `Valor_Ativo_mil` estão em formato americano, com ponto decimal e eventual notação científica.

SH. A série histórica dos fundos tem granularidade fundo $\times$ dia e traz informações de gestora, classificação, nome do fundo e patrimônio líquido. O PL vem em formato brasileiro e é convertido para número com parser específico.

B3/COTAHIST. A CONS não informa quantidade de ações. Para converter a posição em ITUB4 de valor para quantidade estimada, usa-se o fechamento diário oficial da B3/COTAHIST, mercado à vista (TPMERC=010), selecionando o último pregão de cada mês. A amostra de preços cobre os 72 meses entre janeiro de 2016 e dezembro de 2021, sem lacunas mensais.

A ligação entre CONS e SH é feita por `Código` (CONS) igual a `COD_FUNDO` (SH), mantendo o mesmo CNPJ e a mesma data de competência mensal. A revisão de qualidade encontrou apenas 2 fundos-mês da CONS sem correspondência no SH.

3.2 Tratamentos de dados

Os principais tratamentos são:

- normalização de CNPJ para dígitos;

- parser separado para números em formato americano (CONS) e dinheiro em formato brasileiro (SH);
- remoção de linhas exatamente duplicadas na CONS, definidas por mesmo CNPJ, código, data, ativo e valor;
- extração de ticker terminal a partir do nome do ativo;
- classificação das variantes de exposição em direta, cedida e obrigação;
- consolidação de gestoras por grupo econômico via regras de texto;
- conversão de R\$ para US\$ com PTAX de fim de mês (BCB SGS série 1);
- conversão auxiliar de valor de ITUB4 para quantidade estimada de ações com fechamento mensal B3/COTAHIST;
- construção de deltas mensais apenas quando os meses são consecutivos.

A duplicata exata da CONS é um ponto importante. A revisão profunda encontrou cerca de 0,2% de linhas exatamente repetidas, com impacto de aproximadamente 0,01% nos totais. A correção preserva lotes legítimos com valores diferentes e remove apenas cópias idênticas.

3.3 Definição de exposição

Para ITUB4, há três definições:

- **direta**: apenas a linha direta do ativo;
- **long**: direta mais ações cedidas em empréstimo;
- **net**: long mais obrigações por ações recebidas em empréstimo, que entram negativas.

A definição principal é *net*. No período, a soma das posições mensais em ITUB4 é R\$ 468 bi na definição direta, R\$ 540 bi na definição long e R\$ 496 bi na definição net. A definição net gera 264 observações gestora-mês com posição líquida negativa, evidenciando a relevância do aluguel de ações.

3.4 Problema preditivo consolidado

O problema preditivo do corpo do trabalho é consolidado por gestora. Para cada gestora g , ação i e mês t , observa-se a exposição $E_{g,i,t}$ e sua variação $\Delta E_{g,i,t}$. O conjunto das demais gestoras, $-g$, resume o comportamento do restante do mercado naquela ação. Em termos gerais, o sistema de previsão procura usar:

$$\hat{E}_{g,i,t+1} = f(E_{g,i,\leq t}, E_{-g,i,\leq t}),$$

em que $E_{-g,i,\leq t}$ representa a informação agregada ou cruzada do restante do mercado. Neste estágio, o trabalho implementa baselines transparentes: *random walk*, AR, modelos

de painel e PCA/fatores. A CDA aparece no Apêndice A como camada adicional: ela permite escrever uma extensão $f(E_{g,i,\leq t}, E_{-g,i,\leq t}, G_t)$, em que G_t é o grafo fundo-sobre-fundo. Essa extensão usa o grafo como informação, mas o alvo continua sendo a exposição consolidada, não a rede futura.

3.5 Quantidade estimada de ações

Para estudar demanda em sentido estrito, valor monetário não é suficiente. A posição em reais varia tanto por compra e venda de ações quanto por variação de preço. Como a CONS não traz número de ações, a quantidade é estimada por:

$$q_{g,t}^{ITUB4} = \frac{V_{g,t}^{ITUB4} \times 1000}{P_t^{ITUB4}},$$

em que $V_{g,t}^{ITUB4}$ é a posição em `Valor_Ativo_mil` e P_t^{ITUB4} é o fechamento de ITUB4 no último pregão do mês na B3/COTAHIST. A multiplicação por 1000 converte o valor da CONS de mil reais para reais.

A mesma regra é aplicada às variantes direta, cedida e obrigação. Assim:

$$q^{dir} = \frac{1000V^{dir}}{P}, \quad q^{long} = \frac{1000(V^{dir} + V^{ced})}{P}, \quad q^{net} = \frac{1000(V^{dir} + V^{ced} + V^{oblig})}{P}.$$

Aqui, *dir*, *ced* e *oblig* indicam, respectivamente, posição direta, ações cedidas em empréstimo e obrigações por ações recebidas em empréstimo. A definição principal permanece *net*. A validação numérica reconstrói o valor original por $q_{g,t}^{ITUB4} P_t^{ITUB4} / 1000$ com erro máximo de aproximadamente $9,3 \times 10^{-10}$ mil reais, isto é, apenas erro de arredondamento de máquina.

Essa quantidade deve ser lida como robustez e não como substituta da exposição em valor. Ela é a melhor aproximação possível com CONS+B3 para separar efeito de preço de mudança aproximada de demanda, mas eventos societários que alterem mecanicamente o número de ações exigem cautela na interpretação temporal. A medida principal do TCC permanece a exposição em valor, por ser mais direta para risco patrimonial e gerenciamento de risco.

3.6 Unidade de análise

A unidade principal é a gestora consolidada por grupo econômico. Essa decisão torna a análise mais legível e reduz ruído de variações de nomes jurídicos. O painel ITUB4 tem 2.835 observações gestora-mês, cobrindo 42 grupos econômicos e 72 meses.

3.7 Avaliação preditiva

As previsões usam origem móvel com janela expansível. Em cada origem, o modelo é estimado apenas com dados até o mês t e prevê $t + h$. O benchmark é o *random walk*: para a variação, a previsão é $\hat{\Delta} = 0$; para o nível, a previsão é $\hat{y}_{t+h} = y_t$.

As métricas são RMSE, MAE, *skill* contra o *random walk* e acerto de direção. PCA e fatores são estimados somente na janela de treino, sem usar informação futura. A análise em valor é a especificação principal; a análise em quantidade estimada é uma robustez para ITUB4.

Capítulo 4

Resultados

4.1 Exposição e quantidade em ITUB4

O painel mostra que Itaú, Bradesco, BB, Kapitalo e Santander estão entre as maiores exposições médias a ITUB4. A Figura 4.1 resume a exposição em valor, enquanto a Figura 4.2 mostra a quantidade estimada de ações. A diferença entre as duas figuras é substantiva: a primeira mistura preço e quantidade; a segunda isola a aproximação de demanda.




Figura 4.1: Posição em ITUB4 por gestora (US\$ milhões, exposição net).




Figura 4.2: Quantidade estimada de ITUB4 por gestora (milhões de ações, exposição net).

Tabela 4.1: Definições de exposição em ITUB4: valor e quantidade estimada.

Def.	Valor (R\$ bi)	Média (US\$ mi)	Qtd. (bi ações)	Qtd. neg.
direta	468	39,0	14,77	0
long	540	45,1	17,02	0
net	496	41,4	15,71	264

4.2 Extensão para todas as ações

A extensão para todas as ações reconhece 836 tickers e produz um painel gestora $\times$ mês $\times$ ticker. O resultado mais importante do núcleo CONS+SH é a concentração: as ações detidas pelo maior número de gestoras são *blue chips* como VALE3, PETR4, ITUB4, BBDC4 e EQTL3. Isso sustenta a conexão com fragilidade por propriedade comum.




Figura 4.3: Ações detidas pelo maior número de gestoras.

4.3 Leitura complementar da rede

Como a previsão do corpo do trabalho é consolidada por gestora, a rede fundo-sobre-fundo não é necessária para construir o painel principal. Ainda assim, ela é importante para interpretar risco e para preparar uma extensão metodológica com grafos. O Apêndice A documenta a CDA Bloco 2 em detalhe: leitura da base, filtros, validações, visualizações de grafo, teste de circularidade, profundidade de aninhamento e de-duplicação intra-gestora. A leitura correta é que a rede fundamenta uma possível camada de informação; o alvo econométrico continua sendo a exposição consolidada por gestora e ação.

4.4 Previsão da variação mensal

Nas primeiras rodadas de forecasting, o alvo era a variação mensal da posição em US\$ para ITUB4. O resultado já era negativo e informativo: AR, média e PCA não superavam o *random walk*. Ao refazer o exercício em quantidade estimada de ações, como robustez para separar preço e quantidade, a conclusão se mantém. O melhor modelo, AR encolhido, melhora apenas 0,6% no RMSE e piora no MAE. A direção fica em torno de 50%.

Tabela 4.2: Variação mensal da quantidade estimada de ITUB4: *skill* contra random walk.

Modelo	RMSE (mi ações)	Skill RMSE	Skill MAE	Direção
Random walk	5,42	0,0%	0,0%	–
AR encolhido	5,39	+0,6%	-0,9%	50,4%
AR	5,49	-1,2%	-4,9%	50,4%
PCA $k = 1$	6,29	-16,1%	-13,0%	50,0%
PCA $k = 3$	6,19	-14,2%	-25,8%	50,4%




Figura 4.4: *Skill* de RMSE para a variação mensal da quantidade estimada de ITUB4.

A leitura é que a variação mensal, tanto em valor quanto em quantidade aproximada, é difícil de prever com modelos lineares simples. Esse resultado não encerra a pergunta; ele motiva usar informação adicional de mercado e, em uma extensão, informação de rede.

4.5 Previsão do nível e reversão à média

Ao mudar o alvo para o nível da posição em valor, aparece previsibilidade. Para ITUB4, o AR individual reduz o RMSE em cerca de 10% contra o *random walk* nos horizontes de 1 e 3 meses. O modelo de painel melhora em horizontes mais longos, chegando a 9% no horizonte de 6 meses. Esse resultado é relevante para risco patrimonial, mas não deve ser interpretado automaticamente como previsibilidade de compras e vendas de ações.




Figura 4.5: *Skill* contra random walk no nível, por alvo e horizonte.

Como robustez, quando o alvo é o nível da quantidade estimada de ações, a evidência é mais fraca. O AR individual melhora o RMSE em 3,5% no horizonte de um mês, mas perde para o *random walk* em três e seis meses. O modelo de painel também não melhora a previsão. Portanto, a reversão em valor é mais forte do que a reversão em quantidade.




Figura 4.6: *Skill* contra random walk no nível da quantidade estimada de ITUB4.

O refinamento de meia-vida estima explicitamente a velocidade de retorno à alocação-alvo. Para a posição em US\$ de ITUB4, 36 de 37 gestoras reverterem à média; o coeficiente ρ mediano é aproximadamente 0,77 e a meia-vida mediana é 2,8 meses. Para a quantidade estimada, 33 de 37 gestoras reverterem; o ρ mediano sobe para aproximadamente 0,83, a meia-vida mediana vai para 3,8 meses e a meia-vida de painel chega a 6,0 meses. Isso sugere que a demanda em ações é mais persistente e menos previsível do que a exposição em valor.




Figura 4.7: Meia-vida da reversão à alocação-alvo em ITUB4.




Figura 4.8: Meia-vida da reversão da quantidade estimada de ITUB4.

4.6 Generalização do forecasting

A rodada com todas as ações, ainda em valor, mostra que a previsibilidade do nível não é geral. Entre 238 ações elegíveis, a mediana da *skill* é negativa e apenas uma parcela pequena supera o *random walk*. ITUB4 fica entre as melhores, com *skill* próxima de 9,9%, ao lado de outras ações muito líquidas e amplamente detidas. Essa evidência deve ser lida como resultado de exposição patrimonial; a generalização para quantidade exigiria baixar e validar preços mensais para todos os tickers.




Figura 4.9: Distribuição da *skill* AR vs random walk por ação. Linha vermelha: ITUB4.

4.7 Teste complementar com rede

Uma especificação complementar adiciona a exposição dos vizinhos no grafo CDA como preditor do nível da posição. O resultado não melhora o baseline de reversão à média: AR1 de painel tem *skill* de 3,3%, enquanto o modelo com rede tem 3,1%. Esse resultado deve ser lido com cautela. Ele não descarta o uso de redes; mostra apenas que uma feature manual simples, baseada em média de vizinhos, não basta para superar o AR de painel. Como a previsão principal é consolidada, esse teste é apresentado como extensão: o próximo passo metodológico seria comparar uma versão com grafo, usando CDA e restante do mercado, contra os baselines consolidados já estimados.

Capítulo 5

Conclusão

O projeto entrega cinco conclusões principais. Primeiro, é possível construir um painel mensal coerente de exposição consolidada das gestoras a ações usando CONS e SH, com tratamento cuidadoso de formato numérico, empréstimos de ações, grupos econômicos, R\$ e US\$. Segundo, a exposição institucional é concentrada em *blue chips*, o que conecta o exercício à literatura de demanda por ações e fragilidade por propriedade comum. Terceiro, a variação mensal da exposição é difícil de prever com modelos lineares simples; o *random walk* é um benchmark forte. Quarto, o nível da exposição em valor apresenta alguma reversão à média, especialmente em ITUB4 e em ações muito líquidas. Quinto, a quantidade estimada mostra que parte da reversão patrimonial em valor não deve ser confundida com compra e venda previsível de ações.

A interpretação econômica é alinhada à literatura de demanda por ações. Carteiras observadas revelam demanda institucional e permitem estudar quem aumenta ou reduz exposição em cada ação. Ao mesmo tempo, a estrutura de fundos interconectados adiciona uma dimensão de risco, documentada no apêndice CDA: a exposição final pode passar por estruturas FIC/master e por camadas de fundos sobre fundos. Portanto, o caminho natural do TCC é um sistema de previsão consolidada de exposição por gestora e ação, usando histórico próprio e restante do mercado como núcleo; a rede entra como extensão para enriquecer features e interpretar risco.

O resultado negativo da feature manual de rede não fecha a questão. Ele funciona como baseline: uma média de vizinhos não acrescenta sinal suficiente, mas um modelo de grafo mais flexível ainda é metodologicamente coerente como extensão. A próxima etapa é formalizar a previsão em painel gestora $\times$ ação $\times$ mês, com features do restante do mercado, e então comparar uma versão com grafo contra *random walk*, AR, painel e fatores.

Apêndice A

Apêndice: CDA e Estruturas Fundo-Sobre-Fundo

A.1 Por que a CDA aparece no projeto

A CONS é consolidada: ela mostra os ativos finais da carteira, mas apaga relações entre fundos. Se um FIC investe em um master que detém ações, a CONS mostra a exposição final em ações. Isso é ótimo para medir exposição consolidada, que é o núcleo do TCC. Porém, isso é insuficiente para estudar a estrutura fundo→fundo. A CDA Bloco 2 entra somente para esse segundo objetivo: reconstruir a rede de cotas de fundos, avaliar se há circularidade, medir profundidade de aninhamento e produzir uma base auditável para extensões de graph learning.

Essa distinção é essencial. O TCC não depende da CDA para medir exposição em ITUB4, para construir o painel gestora $\times$ ação $\times$ mês, nem para rodar os baselines principais de forecasting. O alvo principal também não é prever a rede. O alvo é prever exposição consolidada. O grafo CDA é uma camada auxiliar para entender a estrutura dos fundos e, no futuro, usar essa estrutura como informação adicional.

A.2 O que é a CDA Bloco 2

A CDA é a Composição e Diversificação das Aplicações dos fundos. O Bloco 2 registra cotas de fundos de investimento. As colunas relevantes usadas no projeto são:

- CNPJ_FUNDO: fundo que detém cotas;
- CNPJ_FUNDO_COTA: fundo investido;
- DT_COMPTC: data de competência;
- VL_MERC_POS_FINAL: valor de mercado da posição;
- DT_CONFID_APLIC: campo associado à confidencialidade de aplicação.

Nos arquivos históricos processados, `DT_CONFID_APLIC` aparece preenchido em 32,3% das arestas, mas `CNPJ_FUNDO_COTA` está disponível e destino vazio é zero. Portanto, o projeto não trata esse campo como sinônimo de destino mascarado.

A.3 Por que uma leitura simples da CDA fica ruim

Uma tentativa como `read_csv("C:/Users/joaoz/Downloads/CDA/cad_fi.csv")` não reproduz o tratamento usado aqui por três motivos.

Primeiro, o arquivo relevante para a rede não é um cadastro genérico de fundos, mas o arquivo histórico anual do documento CDA, especificamente o arquivo do Bloco 2 dentro dos ZIPs anuais da CVM. Segundo, os arquivos da CVM usam separador ponto-e-vírgula e encoding `latin1`; por isso, uma leitura automática com vírgula pode quebrar colunas, acentos e tipos. Terceiro, o arquivo bruto contém muito mais informação do que o necessário. O projeto seleciona apenas as colunas necessárias para construir arestas fundo→fundo e filtra a origem para fundos pertencentes ao universo CONS+SH.

O tratamento usado no projeto está em `R/10_build_cda_edges.R`. A sequência é:

1. baixar, quando necessário, os ZIPs anuais da CVM para 2016–2021;
2. abrir de dentro do ZIP o arquivo `cda_fi_BLC_2_AAAA.csv`, sem extrair todo o ZIP para disco;
3. ler o conteúdo com `sep=";"` e encoding `latin1`;
4. selecionar as cinco colunas essenciais: fundo de origem, data, valor de mercado, fundo investido e campo de confidencialidade;
5. normalizar CNPJs para 14 dígitos;
6. converter `DT_COMPTC` para data e `VL_MERC_POS_FINAL` para número;
7. manter apenas arestas cuja origem aparece no universo de fundos do projeto;
8. marcar se o destino também pertence ao universo CONS+SH.

A saída processada é `data/processed/cda_edges.csv`, com uma linha por posição fundo→fundo observada no Bloco 2. As colunas finais são:

`{ano, data, cnpj_fundo, cnpj_cota, valor_brl, confidencial, dentro_universo}`.

A.4 Construção da base processada

O filtro de origem é deliberado. O objetivo não é reconstruir todo o sistema brasileiro de fundos, mas a rede relevante para os fundos presentes no painel CONS+SH do TCC. Assim, `cnpj_fundo` precisa estar no universo do projeto. Já `cnpj_cota` pode estar dentro ou fora desse universo. Quando o destino está fora, a aresta ainda é economicamente informativa, mas não permite recuperar gestora, PL e exposição final no mesmo painel.

A Tabela A.1 resume a massa de dados por ano. O crescimento do número de arestas é compatível com a expansão do universo observado e com maior densidade de estruturas fundo-sobre-fundo.

Tabela A.1: Resumo da CDA processada.

Ano	Arestas	DT_CONFID	Destino no universo	Destino externo
2016	100.824	22.079	34.212	66.612
2017	105.717	31.805	35.024	70.693
2018	115.763	38.549	38.215	77.548
2019	133.670	50.980	44.651	89.019
2020	166.317	59.650	55.406	110.911
2021	213.403	67.105	67.389	146.014

A.5 Validação da CDA

As principais checagens foram feitas antes de usar a CDA para qualquer interpretação econômica:

- **identidade das arestas:** a aresta é sempre lida como fundo de origem detendo cotas do fundo de destino;
- **CNPJ:** origem e destino são normalizados com a mesma função usada no restante do projeto;
- **datas:** a competência é mensal e compatível com os painéis CONS+SH;
- **valores:** `valor_brl` está em reais, não em mil reais;
- **self-loops:** não há fundo investindo diretamente nele mesmo;
- **duplicatas:** não há duplicatas exatas de arestas no arquivo processado;
- **valores inválidos:** os valores de mercado não têm NAs nem valores negativos;
- **confidencialidade:** `DT_CONFID_APLIC` preenchido não é tratado automaticamente como destino mascarado, porque `CNPJ_FUNDO_COTA` permanece preenchido;
- **fração de propriedade:** quando há PL do destino, calcula-se $\phi = \text{valor} / PL_{\text{destino}}$ para avaliar plausibilidade.

A fração ϕ tem mediana próxima de 0,007 e a grande maioria das observações com PL válido fica em $(0, 1]$. Casos com $\phi > 1$ são raros e foram capados em 1 no cálculo de de-duplicação. Isso é conservador: impede que erro de unidade, defasagem de PL ou diferença de cobertura gere propriedade acima de 100%.

A.6 Visualização dos grafos

As figuras de rede são geradas por `R/21_cda_graph_figures.R`. Elas não são desenhos manuais: partem de `data/processed/cda_edges.csv`. A Figura A.1 mostra o subgrafo fundo→fundo mais conectado em dezembro de 2021, filtrado para os 120 nós de maior grau e removendo isolados. Nós azuis são fundos no universo CONS+SH; nós cinza são origens ou destinos fora do universo principal, mas observados na CDA.




Figura A.1: CDA Bloco 2: subgrafo fundo→fundo mais conectado em dezembro de 2021.

A Figura A.2 projeta as arestas para o nível de gestoras: uma aresta gestora $A \rightarrow$ gestora B aparece quando fundos da gestora A detêm cotas de fundos da gestora B. Essa figura usa apenas arestas entre casas diferentes, para evitar que auto-laços dominem visualmente a rede. Ela não é a base do forecasting principal; serve para mostrar que há interconexões observáveis entre estruturas de fundos.

Projecao gestora->gestora: cotas de fundos entre casas (2021-12-31)



Figura A.2: Projeção gestora→gestora das cotas de fundos entre casas em dezembro de 2021.

No mês de referência usado nas figuras, a CDA processada contém 5.045 nós e 19.191 arestas antes do filtro visual. O subgrafo visualizado tem 96 nós e 258 arestas. A projeção por gestora mostra 45 arestas intergestoras entre 38 grupos, após selecionar as maiores relações por valor.

A.7 Ciclos e profundidade

Uma preocupação natural em estruturas FIC/master é a existência de circularidade: fundo A investe em B, B em C e C volta a A. Essa situação dificultaria a interpretação de exposição look-through. Para testar isso, o projeto constrói, mês a mês, o subgrafo de arestas em que origem e destino estão no universo CONS+SH e usa `igraph::is_dag`. O resultado é: todos os 72 meses são DAGs. Portanto, não encontramos ciclos diretos no subgrafo observado.

Ausência de ciclos não significa ausência de complexidade. O mesmo módulo mede a maior cadeia direcionada em cada mês. A profundidade máxima tem mediana 7 e máximo 9 níveis. Isso indica estruturas de aninhamento relevantes: a exposição final pode passar por várias camadas de fundos antes de chegar ao ativo consolidado.

Tabela A.2: Estrutura da rede CDA no universo observado.

Métrica	Valor
Arestas CDA processadas	835.694
Meses analisados	72
Meses com ciclos	0
Profundidade máxima mediana	7
Profundidade máxima observada	9
Nós no último mês, subgrafo intra-amostra	2.565
Arestas no último mês, subgrafo intra-amostra	5.968

A.8 De-duplicação intra-gestora

Se o fundo A de uma gestora investe no fundo B da mesma gestora, e B tem exposição L_B a uma ação, parte de L_B pode aparecer duas vezes quando somamos fundos da gestora. A fração de B detida por A é:

$$\phi_{A \rightarrow B} = \frac{v_{A \rightarrow B}}{PL_B}.$$

Assim, a exposição de-duplicada por gestora é:

$$\text{dedup}_g = \sum_{i \in g} L_i - \sum_{A \rightarrow B \in g} \phi_{A \rightarrow B} L_B.$$

Para ITUB4, a duplicação intra-gestora estimada é 37,6%. Se também forem consideradas arestas entre gestoras no universo observado, a duplicação rastreável aumenta em cerca de 5,3 pontos percentuais, chegando a 43,0%. Portanto, o número de 37,6% deve sempre ser lido como duplicação *intra-gestora*, não como duplicação total do sistema.




Figura A.3: Itaú: exposição bruta e de-duplicada em ITUB4.

A.9 Como a CDA se conecta a modelos de grafo

É tentador dizer que o projeto “prevê grafos”, mas essa não é a formulação correta no estágio atual. O que o projeto prevê é exposição consolidada:

$$\hat{E}_{g,i,t+h}.$$

O grafo entra como informação auxiliar. Em uma extensão, poderíamos escrever:

$$\hat{E}_{g,i,t+h} = f(E_{g,i,\leq t}, E_{-g,i,\leq t}, G_t),$$

em que G_t é o grafo observado de fundos ou gestoras no mês t . Uma GNN usaria a matriz de adjacência derivada da CDA e atributos dos nós, como exposição atual, variação passada, PL, centralidade, grau e vizinhança. O alvo continuaria sendo exposição futura, não a aresta futura.

O teste já feito com feature manual de rede é uma versão fraca dessa ideia: usa a exposição dos vizinhos no grafo como preditor adicional. O resultado não superou o AR de painel. Isso não prova que todo modelo de grafo falhará; apenas mostra que uma média simples de vizinhos não captura sinal incremental suficiente. Para ser defensável, qualquer GNN futura deve ser comparada contra *random walk*, AR, painel e fatores, sempre com origem móvel e sem vazamento.

A.10 Limitações da CDA

A CDA tem três limitações principais:

1. ela mede relações de cotas de fundos, não exposição final em ações; por isso deve ser usada junto com a CONS, não em substituição a ela;
2. muitos destinos estão fora do universo CONS+SH usado no painel principal, o que limita a cobertura de rede observável;
3. a interpretação de DT_CONFID_APLIC exige cautela e não deve ser descrita como destino mascarado quando o CNPJ do destino está preenchido.

Assim, a CDA deve ser tratada como apêndice técnico robusto: útil, auditado e visualmente informativo, mas separado do núcleo consolidado. A conclusão principal do TCC não depende dela. A contribuição da CDA é mostrar a estrutura de fundos sobre fundos que a CONS apaga, quantificar risco de aninhamento e deixar pronta uma trilha metodológica para modelos de grafo.

Referências Bibliográficas

- Rinaldo Artes and Lúcia Pereira Barroso. *Métodos Multivariados de Análise Estatística*. Blucher, São Paulo, 2023. ISBN 9786555067026.
- B3 S.A. — Brasil, Bolsa, Balcão. Cotações históricas — cotahist. <https://bvmf.bmfbovespa.com.br/InstDados/SerHist/>, 2024.
- Maurício Ferraresi Junior. Replicant investment platforms. Working paper. Citação bibliográfica exata a confirmar com o orientador., 2024.
- Xavier Gabaix and Ralph S. J. Koijen. In search of the origins of financial fluctuations: The inelastic markets hypothesis. NBER Working Paper 28967, National Bureau of Economic Research, 2021. <https://www.nber.org/papers/w28967>.
- Robin Greenwood and David Thesmar. Stock price fragility. *Journal of Financial Economics*, 102(3):471–490, 2011.
- Ralph S. J. Koijen and Motohiro Yogo. A demand system approach to asset pricing. *Journal of Political Economy*, 127(4):1475–1515, 2019. doi: 10.1086/701683.
- Benjamin Sanchez-Lengeling, Emily Reif, Adam Pearce, and Alexander B. Wiltschko. A gentle introduction to graph neural networks. *Distill*, 2021. <https://distill.pub/2021/gnn-intro/>.